Day 2

☑ 今天做了：

1.明确RAG核心定义与要解决的核心问题

主要有下面内容：

RAG（Retrieval-Augmented Generation，检索增强生成）核心：先从外部知识库检索相关信息，再用大模型基于这些信息生成答案，从架构上解决LLM的三大痛点（幻觉、知识滞后、不可追溯）

传统LLM四大固有缺陷：知识幻觉（编造错误事实）、知识陈旧/封闭（训练后知识冻结）、不可追溯/不可控（来源不明，不适合严谨场景）、领域知识薄弱（垂直领域理解不足）

RAG核心解法：不修改模型权重，外挂可随时更新的“动态知识库”，推理时先检索再生成，确保答案基于外部事实、可溯源

2.RAG全流程

1.文档收集与切割

2.向量化与存储：嵌入（Embedding）模型，是整个Rag梦的开始，在高维空间上面来看，语义相近的文档块，会天然的考的很近，语义无关则相反，当然整个也是经过训练后得到的。向量被存储进向量数据库当中，建立索引，等待被检索。

3.检索与匹配：我们在向量化中提到了，语义相近的文档块，会天然的考的很近。这个就是检索与匹配的基石，方法有两个 余弦相似度与欧氏距离

4.增强生成：通过构造一个Prompt来完成（参考资料+用户问题）。

在线推理（提问后，问答全链路）：

查询预处理：对用户问题纠错、扩写等，提升检索召回率，避免口语化导致检索失败

检索（粗召回）：用户问题向量化后，计算向量相似度，返回Top-K相关Chunk，快且覆盖全但精度一般

重排序（精排，高质量RAG必备）：用Cross-Encoder重排模型打分，筛选Top3-5精准片段，检索精度提升30%-50%，降低幻觉

Prompt工程：按固定模板拼接上下文，控制长度、标注来源、强制事实约束

生成与后校验：LLM生成答案后，通过模型自检和事实核对进行幻觉校验，输出带引用标注的可溯源答案

3.了解RAG的迭代演进路径

朴素RAG（基础版）：流程为切块→向量→检索→生成，无重排、无改写、无校验，存在召回差、幻觉高的问题

高级RAG：离线优化（语义切块、元数据增强等），在线优化（查询改写、重排等）

模块化/自适应RAG（下一代）：具备动态路由、自我优化、多模态检索三大特点

4.掌握高质量RAG的关键技术要点

数据质量>模型大小：清洗、去重、标准化是前提，脏数据会导致脏检索、脏答案

分块是核心：语义切块+重叠是最优解，避免切块过小丢失上下文、过大检索不准

重排是精度天花板：无重排的RAG难以达到企业级可用

向量模型选型：垂直领域需用领域微调嵌入模型

可观测性：监控召回率、精确率等指标，持续迭代优化

📋 今日感悟：

RAG并非简单的“搜索+LLM”，而是一套完整的技术体系，其核心价值在于用“检索增强”破解LLM的固有痛点。从朴素RAG到高级RAG的演进，体现了技术从基础到完善的迭代逻辑，每一个环节的优化（如重排、语义分块）都在朝着“更精准、更可控、更实用”的方向前进，而数据质量与细节把控，正是构建高质量RAG知识库的核心前提。