多模态 （ai是怎么样一步步走到能看能听能说的呢？）

1.什么是模态

模态=信息的载体形式，包含文本、图像、音频、视频

人类天然多模态，早期大模型仅支持文本，无法处理非文本信息

2.什么是多模态AI

多模态AI=突破**纯文本限制**，可理解+生成多类型信息

核心能力：**能看、能听、能说、能画** 支持模态：**文本、图像、音频、视频**

3.多模态AI实现路线

路线一：**管线式(Pipeline)**，翻译接力赛

1.非文本信息转文本交给大模型处理 2.结果转回原格式输出

优点：模块可独立替换优化，可控易排查 缺点：信息丢失，延迟叠加

路线二：**原生多模态(Native Multimodal)**，全能选手

优点：信息无丢失，延迟低，跨模态理解强 缺点：训练成本高，单环节难优化 现状：2026年初以管线式为主，混合方案更常见

4.语音识别(ASR)：语音→文字

ASR=自动语音识别，将语音转为文本

应用：语音助手、会议纪要、字幕、智能客服

进化四代：1.传统规则 2.深度学习 3.端到端 4.大规模预训练

核心模型：**Whisper**(OpenAI开源通用)、**FunASR**(中文优化)

关键能力：流式识别(低延迟边说边转)、离线识别(高准确率)、**VAD**(语音活动检测，过滤静音噪音)

5.语音合成(TTS)：文字→语音

TTS=文字转语音，与ASR反向

应用：导航、有声书、智能客服播报

进化四代：1.片段拼接 2.参数合成 3.神经网络 4.大模型+克隆+情感

关键能力：声音克隆(短音频复刻音色，高价值高风险)、**MOS**(语音质量评分，4分可用4.5分优秀)

6.OCR与文档理解：图片→文字

OCR=光学字符识别，提取图片文字

应用：拍照翻译、证件识别、搜题、笔记提取

进化四阶段：1.单字识别 2.场景文字 3.文档理解(版面+表格+公式) 4.多模态理解(VLM直接问答)

7.视觉语言模型(VLM)：大模型+眼睛

VLM=让大语言模型具备图像理解能力，实现看图交互

实现步骤：1.ViT视觉编码器转图片为数字 2.投影层适配大模型 3.图文信息联合输入推理

应用：文档理解、商品识别、工业质检、图表分析、界面理解

8.图像生成：AI画画

主流方法：**扩散模型(Diffusion Model)**

训练：清晰图加噪，学习去噪还原

生成：随机噪声逐步去噪，文本引导方向

技术路线：1.扩散模型(主流高清：SD、DALL-E3、Flux) 2.自回归模型(Emu3) 3.GAN(StyleGAN，非主流)

核心工具：**Stable Diffusion**(开源主流)、**LoRA**(轻量风格插件)、**ControlNet**(构图姿态控制)、**ComfyUI**(可视化工作流)

记忆点：AI画画=扩散模型，噪声去噪生成

9.视频生成与理解：AI拍电影

视频生成：图像生成进阶，需帧间连贯+物理合理

代表模型：Sora2(OpenAI)、Wan2.6(阿里)、Kling(快手)、Runway Gen-4、Pika，Sora已关停

视频理解应用：审核、摘要、监控分析、直播商品识别

10.实时语音对话：低延迟自然交互

核心难点：低延迟、打断处理、回声消除、情感连贯

两种方案：1.管线式(ASR+大模型+TTS，延迟高可控) 2.端到端(音频直出，低延迟保情绪，代表GPT-4o Realtime、GLM-4-Voice、MiniCPM-o)

11.全模态模型(Omni)：一个模型通吃

全模态模型=原生统一处理多模态理解与生成

代表：GPT-4o/GPT-5、Gemini3、Qwen3.5-Omni、MiniCPM-o、GLM-4-Voice

对比管线式：管线式可控低成本，全模态低延迟理解深

共存原则：成本工程选管线，体验延迟选全模态