大模型微调（Fine-tuning）学习总结

前言

我们在前四天的学习当中已完成机器学习/深度学习、Transformer、提示词工程、RAG、Agent、Harness 学习；提示词与RAG无法从根本改变模型性格与能力边界，需微调从参数层面定制模型。

注意：大模型应用开发不常问微调，但会微调是加分项。

一、为什么需要微调：大模型的"通才困境"

1.1 通才 vs 专才

大模型为通用通才，微调是专科培训，**保留通用能力，获得领域专业能力。**

1.2 微调能做什么

1. **风格定制**：稳定固化回答语气、话术
2. **领域知识注入**：理解并运用专业知识推理
3. **行为对齐**：规范回答行为，减少幻觉与生硬回复

1.3 微调 vs RAG vs 提示词工程

- 提示词工程：任务说明书，每次重写，改**怎么问**
- RAG：资料柜，外部查询，改**能查到什么**
- 微调：岗前培训，内化能力，改**模型本身**

最佳实践：**三者组合使用**

1.4 全量微调 vs 高效微调

- 全量微调（FFT）：训练全部参数，效果好、成本高、显存需求大
- 高效微调（PEFT）：训练<1%参数，显存低、成本低、效果接近全量

结论：**99%场景用PEFT（LoRA），全量微调为土豪专属**

二、大模型训练全景：三阶段

1. **预训练**：学知识，成本极高、普通团队不做
2. **指令微调（SFT）**：教听话，核心战场，数据质量>数量
3. **对齐**：教靠谱，让回答有用、安全、符合人类偏好

口诀：**预训练给知识，SFT教听话，对齐让靠谱**

三、高效微调（PEFT）技术全景

3.1 显存速算

- 推理显存（FP16）：参数量(B) × 2（GB）
- 训练显存：推理显存 × 5~7
- PEFT：显存降至1/5甚至更低

3.2 PEFT四大流派

1. **Adapter**：插入小模块，推理有延迟
2. **Soft Prompt**：加虚拟token，占上下文、效果不稳
3. **LoRA系列**：低秩矩阵，**无推理开销、主流首选**
4. **Selective**：选部分参数，依赖经验、通用性差

结论：**重点掌握LoRA，知晓其他三种即可加分**

四、LoRA：高效微调核心

4.1 核心直觉

全量微调仅少量参数被显著修改，只需训练这部分。

4.2 低秩分解

用两个小矩阵A、B近似权重更新量ΔW，参数量缩减百倍。

4.3 关键超参数

- rank（r）：4~16常用，简单4、复杂16+
- target_modules：优先选注意力层Q、V矩阵
- alpha：常与rank相等

4.4 优势

可合并无推理开销、效果接近全量、多LoRA可叠加、文件极小

4.5 QLoRA

4-bit量化+LoRA，7B模型训练显存降至**6GB**，消费级显卡可跑

4.6 进化版本

- DoRA：分解权重微调，效果更优
- rsLoRA：稳定高rank训练

五、模型量化：低成本部署

5.1 本质

用低精度存储参数，减少显存与计算量。

5.2 主流量化方案

- GPTQ：逐层量化，GPU推理快
- AWQ：激活感知，保留重要权重精度
- BitsAndBytes：QLoRA核心，易用
- GGUF+llama.cpp：本地部署标准，CPU可跑

5.3 与微调关系

- 先微调后量化：生产主流
- 量化后微调：QLoRA，省显存
- 只量化不微调：资源受限部署

六、对齐技术：让模型靠谱

6.1 目标

解决幻觉、有害内容、回答质量不稳问题。

6.2 主流方法

1. **RLHF**：经典，需奖励模型+PPO，复杂
2. **DPO**：直接偏好优化，**当前主流**，简单稳定
3. **GRPO**：规则自动打分，无需人工标注
4. RLAIF：AI替代人工标注，成本低

七、微调数据工程

7.1 常用格式

- **Alpaca**：单轮指令，instruction/input/output
- **ChatML**：多轮对话，system/user/assistant

7.2 数据来源

- 开源数据集
- 合成数据（主流）
- 人工标注（高质量、高成本）

7.3 核心原则

数据质量>数量，高质量小数据集效果更佳。

八、微调工程实践

8.1 主流工具链

- LLaMA-Factory：新手友好，Web UI
- Unsloth：速度快、省显存
- Transformers+PEFT：生产灵活
- TRL：对齐训练专用

8.2 标准流程

选基座模型 → 准备数据 → 选择微调方法 → 配置参数 → 训练 → 评估 → 部署

8.3 硬件选型

- 消费级：RTX 4060/4090，学习实验
- 云GPU：A100/H100/L40S，企业项目

九、主流开源模型微调生态（2026）

9.1 三巨头

1. **Qwen**：中文最强，商用友好
2. **DeepSeek**：推理顶尖，协议宽松
3. **LLaMA**：英文强，生态成熟

9.2 选型依据

显存匹配、语言能力、开源协议、社区生态

十、面试高频与总结

10.1 核心问答

1. 微调：内化能力，从根本改变模型
2. LoRA：低秩矩阵近似，小参数、无开销
3. QLoRA：量化+LoRA，极低显存
4. RLHF vs DPO：前者复杂，后者简化主流
5. 数据：质量远大于数量
6. 显存：7B FP16推理14GB，QLoRA训练6GB

10.2 技术选型决策树

- 简单需求→提示词
- 知识常更新→RAG
- 风格/行为/固定知识→微调
- 生产→组合使用